

BAHBench 复现数据整理 最终版

数据清单、论文版 Transformer、LoRA 秩扫描、论文表 III 对照与复现缺口

整理日期：2026-09-21。结果来源：AutoDL Host 002 /root/bahbench-repro/results。

文档结论

当前已完成三轮实验：论文版 Transformer 的 3 个模型 × 3 个任务、HuBERT-base 的 LoRA 秩扫描 $r=2,4,8,16$ ，以及自动曲线图。复现结构已经对齐到 “冻结编码器 → 768 维投影 → 单层 Transformer → 分类头”，但数据版本、官方 split、音频截断和完整模型矩阵仍未对齐，因此数值比较必须标注为近似比较。

最接近论文的是 TORGO：HuBERT-base Transformer 的 WF1 为 0.9606，LoRA $r=16$ 达到 0.9911，与论文最佳 TORGO 结果 0.991 基本一致。ICBHI 仍明显偏低，最好 LoRA $r=2$ 的 WF1 为 0.8890，论文 HuBERT-base 为 0.930。SEP-28k 的 LoRA $r=16$ 为 0.7911，高于论文 HuBERT-base 0.747，但当前数据不是完整 SEP-28k，UA 仍偏低。

一、数据清单与状态

论文任务	云端数据	数量	标签	当前状态	说明
Snore	ESC-50	2,000	50 类	部分	仅为 Snore 来源之一，缺 Kaggle 与 12,000 条二分类版本
ICBHI	/root/autodl-tmp/extra/icbhi	920	8 类	完整	随机 split: 642/134/144; 论文为 539/381
MSTI	/root/autodl-tmp/raw/msti	6,661	无类别列	阻塞	有音频和转写，缺官方 25 类标签
TORGO	/root/autodl-tmp/extra/torgo/wav	8,990	2 类	可用但口径不同	论文为 8,216; 当前 split 6292/1347/1351
SEP-28k	/root/autodl-tmp/bahbench-data/SEP-28k	8,800	2 类	部分	论文约 27,922; 当前 split 6159/1319/1322
FluSense	仅标注	0 音频	9 类标注	阻塞	官方音频未入云端
非论文数据	Speech Commands / CoughVid / Coswara	64,727 / 10,833 / 23,638	多类	代理	不属于 BAHBench 六任务




图 1 六任务数据就绪度：音频、标签、论文样本量与论文 split 的覆盖情况

二、复现协议

组件	实现	是否符合论文
基础模型	冻结 HuBERT/wav2vec2 权重	是
下游	投影到 768 → 单层标准 Transformer → 分类头	是
Transformer 层数	num_layers=1	是
Transformer 参数	nhead=8, dim_feedforward=3072, dropout=0.5	是
训练参数	batch=32, epochs=50, lr=5e-4, weight_decay=1e-2	是
LoRA	Q/K/V, B 初始化为 0, 只训练 LoRA 与下游	方向一致
split	70%/15%/15% 分层随机	否

音频长度	统一截到 6 秒	否，论文未明确截断
手工特征	27 维简化声学特征	否，论文为 eGeMAPS/ComParE

三、实验目的与对比点

实验组	目的	对比点	当前数据
论文版 Transformer	复现论文统一主结构	HuBERT-base vs wav2vec2-base vs wav2vec2-large；与论文表 III 同模型比较	ICBHI / TORGO / SEP-28k
论文差异标记	判断复现数值是否对齐	当前 WF1 减论文 WF1，按 $\pm 2pp$ 标记接近/偏低/偏高	3 任务 $\times$ 3 模型
base vs large	验证大模型是否一定更好	同任务比较 wav2vec2-base 与 wav2vec2-large	ICBHI / TORGO / SEP-28k
任务类型对比	验证声学类与语义类任务差异	ICBHI、TORGO 与 SEP-28k 的 WA/UA/WF1 走势	3 个任务
LoRA 秩扫描	验证容量-性能拐点与 UA 退化	同一模型/任务下比较 $r=2,4,8,16$	ICBHI / TORGO / SEP-28k
数据就绪度	解释为什么不能严格对表	论文样本量与 split vs 当前数据状态	6 个论文任务

四、论文版 Transformer 完整结果

任务	模型	WA	UA	WF1	论文 WA/UA/WF1	$\Delta WF1$	对照标记
ICBHI	HuBERT-base	0.8472	0.2241	0.8281	0.924/0.326/0.930	-10.19	低于论文
ICBHI	wav2vec2-base	0.8750	0.3223	0.8682	0.911/0.240/0.903	-3.48	低于论文
ICBHI	wav2vec2-large	0.8333	0.1250	0.7576	0.916/0.200/0.876	-11.84	低于论文
TORGO	HuBERT-base	0.9608	0.9509	0.9606	0.979/0.976/0.979	-1.84	接近论文
TORGO	wav2vec2-base	0.9408	0.9399	0.9412	0.902/0.887/0.901	+4.02	高于论文但口径不同
TORGO	wav2vec2-large	0.8934	0.8830	0.8940	0.858/0.841/0.857	+3.70	高于论文但口径不同
SEP-28k	HuBERT-base	0.7481	0.6283	0.7344	0.747/0.740/0.747	-1.26	接近论文
SEP-28k	wav2vec2-base	0.7262	0.6088	0.7149	0.692/0.693/0.693	+2.19	高于论文但口径不同
SEP-28k	wav2vec2-large	0.7413	0.5000	0.6312	0.732/0.710/0.724	-9.28	低于论文




图 2 论文版 Transformer 在 ICBHI、TORGO、SEP-28k 上的 WA/UA/WF1

五、与原论文表 III 对照

标记规则：WF1 差异在 $\pm 2\text{pp}$ 内标为“接近论文”；负值标为低于论文；正值标为高于论文但口径不同。当前结果的数据版本和 split 与论文不同，不能把差值全部归因于结构或模型。




图 3 当前论文版 Transformer 相对论文表 III 的 $\Delta WF1$ 热力图

六、LoRA 秩扫描

对象：HuBERT-base + 论文版 Transformer + LoRA Q/K/V。秩范围：2、4、8、16。每个实验均使用 50 epoch、batch 32。

任务	秩 r	WA	UA	WF1
ICBHI	2	0.8889	0.3952	0.8890
ICBHI	4	0.8333	0.3631	0.8502
ICBHI	8	0.8750	0.3055	0.8603
ICBHI	16	0.8750	0.3560	0.8698
TORGO	2	0.9882	0.9870	0.9882
TORGO	4	0.9874	0.9858	0.9874
TORGO	8	0.9889	0.9863	0.9889
TORGO	16	0.9911	0.9898	0.9911
SEP-28k	2	0.7844	0.6833	0.7751
SEP-28k	4	0.7905	0.6664	0.7730

SEP-28k	8	0.7920	0.6979	0.7844
SEP-28k	16	0.8011	0.7002	0.7911






图 4 ICBHI、TORG、SEP-28k 的 LoRA 秩扫描曲线，圆点标出最佳 WF1




图 5 每个任务最佳 LoRA WF1 与论文 HuBERT-base WF1 对比

七、关键结论

- TORGO 最好: LoRA $r=16$ 的 $WF1=0.9911$, 达到论文 TORGO 最佳 0.991 的水平。
- ICBHI 仍偏弱: LoRA 最佳 $r=2$ 的 $WF1=0.8890$, 低于论文 HuBERT-base 0.930, 且 UA 仅 0.3952, 类别不平衡仍严重。
- SEP-28k 有提升: LoRA $r=16$ 的 $WF1=0.7911$, 高于论文 HuBERT-base 0.747, 但 UA 为 0.7002, 低于论文 0.740。
- 秩趋势不是单调提升: ICBHI 最佳 $r=2$, TORGO/SEP-28k 最佳 $r=16$; 论文所谓 $r=16$ 只是经验拐点, 不是普适常数。
- 当前结果只能作为结构对齐后的近似复现; 官方 split、完整数据量和完整模型矩阵仍未完成。

八、复现缺口与优先级

优先级	缺口	影响	下一步
P0	官方 split	数值不可严格对表	ICBHI 539/381; TORGO 6572/1644; SEP 24922/2000/1000
P0	音频截断	ICBHI 10–90 秒被截为 6 秒	按论文口径取消或调整截断
P0	逐层 Transformer	图 2/3 的层偏好未完整复现	用 --layer 扫描每一层，而不是线性探针
P1	手工特征	表 III 手工特征行不可比	补 eGeMAPS 88 维、ComParE-2016 6373 维
P1	完整模型矩阵	只有 3/12 个基础模型配置	补 OPERA-CT、WavLM、Whisper、data2vec、CLAP、HuBERT-large
P1	统计稳定性	单次运行，缺少波动范围	多随机种子、mean±std、per-class 指标
P1	SOTA 对照	未复现表 IV 的任务专用方法	补 ICBHI、SEP-28k、FluSense 的 SOTA 对照
P2	六任务完整覆盖	Snore/MSTI/FluSense 阻塞	补数据或明确标注为不可复现

九、数据与结果文件

类型	路径
结构化数据	D:/a/bahbench_doc/final_data/transformer_results.csv; lora_rank_results.csv
图表	D:/a/bahbench_doc/assets/final_*.png; data_readiness.png
最终文档	D:/a/bahbench_doc/BAHBench_复现数据整理_最终版.docx
云端代码	/root/bahbench-repro/src/paper_transformer.py; plot_rank_sweep.py
云端结果	/root/bahbench-repro/results/paper_transformer_*/; paper_transformer_lora_*/; plots/