

BAHBench 可复现性研究

论文版 Transformer、LoRA 与特征层消融实验

复现实验论文

基于 AutoDL RTX 3090 的 ICBHI、TORGO 与 SEP-28k 复现实验

代码版本: GitHub v0.3.2

摘要

本文复现 BAHBench 论文中可运行的核心实验，重点考察统一 Transformer 下游结构、LoRA 秩、池化方式和特征层选择。复现实现冻结 HuBERT-base、wav2vec2-base 和 wav2vec2-large 编码器，将音频表示投影到 768 维，并通过单层标准 Transformer 与线性分类头完成分类。实验在 ICBHI、TORGO 和 SEP-28k 三个任务上进行，统一报告 WA、UA 和 WF1。论文版 Transformer 结果显示，TORGO 与论文结果最接近，HuBERT-base 的 WF1 为 0.9606；ICBHI 仍存在明显的多数类偏置；SEP-28k 的 WA/WF1 接近论文，但 UA 偏低。LoRA 秩扫描表明最佳秩随任务变化：ICBHI 的最佳秩为 $r=2$ ，TORGO 和 SEP-28k 的最佳秩为 $r=16$ 。进一步的两维实验显示，TORGO 在每类 50、100、200 和 500 个样本时最佳秩依次为 $r=2$ 、 $r=2$ 、 $r=8$ 和 $r=16$ ，说明数据量增加会使拐点右移。TORGO 池化对比中 max pooling 的 WF1 为 0.9792，高于 cls 的 0.9563 和 mean 的 0.9511。跨任务层选择结果显示，ICBHI 和 TORGO 的最佳层均为 layer 1，SEP-28k 的最佳层为 layer 10，支持声学任务偏低位层、语义任务偏高位层的方向性结论。本文同时提供代码编号、运行脚本、SHA256 校验和输出路径，以提高复现透明度。由于当前数据版本、官方 split 和样本量尚未完全对齐，本文的数值结论均按近似复现处理。

关键词：BAHBench；声学基础模型；Transformer；LoRA；可复现性；WA/UA/WF1

1 引言

BAHBench 将 Snore、ICBHI、MSTI、TORGO、SEP-28k 和 FluSense 六个健康相关音频任务放入统一下游框架，比较 12 个声学基础模型和两类手工特征。[1] 论文的核心价值在于统一数据划分、下游结构和评价指标，从而减少不同研究之间的协议差异。

本文聚焦当前已经具备可运行数据的三个任务：ICBHI、TORGO 和 SEP-28k。复现目标是验证论文的统一 Transformer 结构、比较 HuBERT 与 wav2vec2 系列模型，并分析 LoRA 秩对下游性能的影响。Code C1-C16 给出本文使用的全部复现代码。

2 方法

2.1 统一 Transformer 下游结构

基础模型权重被冻结，仅更新投影层、单层标准 Transformer 和分类头。[C1] 对输入音频 x ，基础模型输出 $h=f(x)$ ，投影层将 h 映射到 $d=768$ ，Transformer 输出再送入分类器：

$$\mathbf{h_tilde} = \text{Transformer}(\text{Projection}(\mathbf{h})); \mathbf{p} = \text{Classifier}(\mathbf{h_tilde}[0])$$

代码实现见 `src/paper_transformer.py` 中的 `PaperTransformer` 类 [C1]。下游只使用一层 `TransformerEncoderLayer`，不以多层堆叠替代论文结构。

2.2 LoRA

LoRA 将原始线性权重 W 冻结，仅训练低秩增量 BA ，前向为 $Wx+BAx$ 。[C2] 本文把 LoRA 插入注意力 Q/K/V 投影， B 初始化为零，因此训练起点与原始模型一致。秩扫描范围为 $r=2、4、8、16$ 。

2.3 数据与评价指标

代码统一读取 16 kHz 音频 [C3]，评价指标按论文定义计算 WA 、 UA 和 $WF1$ [C4]。当前复现使用固定随机种子 0 的 70%/15%/15% 分层 split；论文使用各数据集固定 split。两者差异在结果解释中明确标注。

2.4 目标对比点与复现判定

为了让读者不只看模型分数，本文把论文目标、对比对象、判定标准和证据来源逐项列出。完整机器可读版 本见 TARGET_COMPARISON.csv [C12]，复现步骤见 REPRODUCIBILITY_CHECKLIST.md [C11]。

目标结论	论文解读依据	对比点	判定标准	当前状态	代码/证据
轴一：学习特征优于手工特征	\$9.1/\$9.6-1	同一音频、split、探针下，模型特征 vs eGeMAPS/ComParE	学习特征 $WA/UA/WF1$ 显著更高	未完成；需补真实手工特征	补真实手工特
轴二：领域/多样预训练可能优于通用预训练	\$9.2/\$9.6-3	固定架构与规模，只换预训练语料	领域或多样预训练模型稳定更高	未完成	OPeRa-CT/WavLM/RT-large
轴三：不同监督形式能否分离	\$9.3	同一端到端下游比较 SSL/弱监督/配对监督/领域监督	不同监督形式收益可分离	未做；论文未隔离该轴	需改协议
轴四：LoRA 秩增大后收益饱和	\$9.4/\$9.6-2	固定模型与数据，只改变 $r=2,4,8,16,32,64$	找到 $WF1$ 拐点，并检查 WA/UA 退化	部分完成： $r=2,4,8,16$ 与样本量二维扫描完成； $r=32,64$ 未跑	C1、C2；图
层选择：声学偏低中层，语义偏高层的特征	\$6.4/\$9.5	只改变基础模型 --layer，比较各层 $WF1/UA$	12 层：最佳层 1-6 为低中层，7-12 为高层，差距<1pp 为无偏好	已完成五层对比：ICBHI/TORGO 最佳 layer 1，SEP-28k 最佳 layer 10	C21、C22；
base vs large：大模型不一定更好	\$6.2/\$9.5	同任务同 split 只比较 base 与 large	large 不必然更高，反超需记录	已完成三模型对比	图 2
不平衡时 WA/UA 分岔，类别加权可能改善 UA	\$5/\$9.5	$WA-UA$ 差异、per-class recall、加权开/关	WA 高而 UA 低；加权后 UA 上升	WA/UA 趋势已复现，加权未做	图 3/6
池化方式：均值 vs 最大池化	\$9.5	同模型/任务/层只换池化	比较两种池化差异	已完成：max $WF1=0.9792$ ，高于 $cls=0.9563$ 和 $mean=0.9511$	C17、C18；
样本量 $\times$ 秩：拐点是 否随数据量移动	\$11.1-A2/\$9.5	每类样本数与 LoRA 秩二维扫描	样本量增大时最佳秩是否右移	已完成：最佳秩 $2 \rightarrow 2 \rightarrow 8 \rightarrow 16$	C19、C20；
最小复现集	\$9.6	层探针+手工特征；frozen/LoRA/秩扫描；领域数	按顺序完成三项	第 2 项核心结果完成；第 1 和第 3 项未完成	C7、C8、C2

		据			
--	--	---	--	--	--

启动状态	目标对比点	需要补什么
已运行/可直接运行	layer sweep 五层; base vs large; LoRA r=2,4,8,16; 池化; 样本量×秩; WA/UA 分岔与混淆矩阵	上述结果已生成; 代码和图表已归档
需补依赖	轴一模型特征 vs eGeMAPS/ComParE; 轴二领域/多样预训练	openSMILE、真实手工特征、OPERA-CT、WavLM、HuBERT-large
需补代码	类别加权开/关	需要在 paper_transformer.py 和实验编排中增加加权开关
需补数据或协议	严格表 III 数值复现; 完整六任务	官方 split、完整 SEP-28k、Snore、MSTI、FluSense、统一预处理
协议限制	轴三监督形式分离	论文混合 SSL/弱监督/配对监督/领域监督, 不能直接隔离

层选择的实际做法是：以 HuBERT-base 的 12 层为例，hidden_states 的 0 表示卷积前端，1-6 表示低层/中层，7-12 表示高层。保持模型、任务、split、seed 和下游 Transformer 完全一致，只改变 --layer。本文完成 1、4、7、10、12 五个层的对比：ICBHI 和 TORGO 的最佳 WF1 均出现在 layer 1，SEP-28k 的最佳 WF1 出现在 layer 10；因此结果支持声学类任务偏好低中层、语义类任务偏好高层这一方向性结论。由于尚未覆盖全部 12 层，本文不把这组结果解释为严格的层级因果排序。

他人复现本论文时，需要同时满足：获得对应数据集和 manifest、安装 environment.md 中的依赖、按 run.sh 执行实验，并使用 TARGET_COMPARISON.csv 的判定标准检查输出。当前代码包可以验证代码链路，但数据版本、官方 split 和完整模型矩阵仍是数值复现的前提。

3 实验设置

项目	设置
基础模型	facebook/hubert-base-ls960; facebook/wav2vec2-base; facebook/wav2vec2-large
任务	ICBHI (8 类) ; TORGO (2 类) ; SEP-28k (2 类)
下游结构	投影到 768 维; 单层 Transformer; nhead=8; dim_feedforward=3072; dropout=0.5
训练	batch=32; epochs=50; AdamW; lr=5e-4; weight_decay=1e-2; seed=0
LoRA	Q/K/V; r=2,4,8,16; B 初始化为 0
指标	WA、UA、WF1; 并保存测试集 y_true/y_pred




图 1 六任务数据就绪度：论文数据量、标签和 split 与当前数据的覆盖差异

4 复现结果

4.1 论文版 Transformer

任务 / 模型	WA	UA	WF1	论文 WA/UA/WF1	Δ WF1	标注
ICBHI / HuBERT-base	0.8472	0.2241	0.8281	0.924/0.326/0.930	-10.19	低于论文
ICBHI / wav2vec2-base	0.8750	0.3223	0.8682	0.911/0.240/0.903	-3.48	低于论文
ICBHI / wav2vec2-large	0.8333	0.1250	0.7576	0.916/0.200/0.876	-11.84	低于论文
TORGO / HuBERT-base	0.9608	0.9509	0.9606	0.979/0.976/0.979	-1.84	接近论文
TORGO / wav2vec2-base	0.9408	0.9399	0.9412	0.902/0.887/0.901	+4.02	高于论文但口径不同
TORGO / wav2vec2-large	0.8934	0.8830	0.8940	0.858/0.841/0.857	+3.70	高于论文但口径不同
SEP-28k / HuBERT-base	0.7481	0.6283	0.7344	0.747/0.740/0.747	-1.26	接近论文
SEP-28k / wav2vec2-base	0.7262	0.6088	0.7149	0.692/0.693/0.693	+2.19	高于论文但口径不同
SEP-28k / wav2vec2-large	0.7413	0.5000	0.6312	0.732/0.710/0.724	-9.28	低于论文




图 2 论文版 Transformer 在三个任务上的 WA、UA、WF1

4.2 与论文表 III 的差异

图 3 给出当前结果与论文表 III 的 $\Delta WF1$ 。TORGO 的 HuBERT-base 与论文差距最小；ICBHI 的 wav2vec2-large 低于论文 11.84 个百分点；SEP-28k 的 wav2vec2-large 低于论文 9.28 个百分点，且 UA 为 0.5000，说明模型退化为多数类预测。




图 3 当前论文版 Transformer 相对论文表 III 的 $\Delta WF1$ 热力图

4.3 LoRA 秩扫描

任务 / 秩	WA	UA	WF1
ICBHI / r=2	0.8889	0.3952	0.8890
ICBHI / r=4	0.8333	0.3631	0.8502
ICBHI / r=8	0.8750	0.3055	0.8603
ICBHI / r=16	0.8750	0.3560	0.8698
TORGO / r=2	0.9882	0.9870	0.9882
TORGO / r=4	0.9874	0.9858	0.9874
TORGO / r=8	0.9889	0.9863	0.9889
TORGO / r=16	0.9911	0.9898	0.9911

SEP-28k / r=2	0.7844	0.6833	0.7751
SEP-28k / r=4	0.7905	0.6664	0.7730
SEP-28k / r=8	0.7920	0.6979	0.7844
SEP-28k / r=16	0.8011	0.7002	0.7911




图 4 论文版 Transformer 下的 LoRA 秩扫描曲线；圆点标出 WF1 最佳值




图 5 三个任务的最佳 LoRA WF1 与论文 HuBERT-base 对比

LoRA 结果呈现明显任务依赖：ICBHI 最佳 r=2，WF1=0.8890；TORGO 最佳 r=16，WF1=0.9911；SEP-28k 最佳 r=16，WF1=0.7911。该结果说明秩饱和阈值不是固定常数。

4.4 池化方式对比

池化方式	WA	UA	WF1
cls	0.9563	0.9501	0.9563
mean	0.9511	0.9426	0.9511
max	0.9793	0.9750	0.9792




图 6 TORGO 冻结 HuBERT-base 下的池化方式对比

在 TORGO 的固定模型、固定数据 split 和固定训练协议下，max pooling 的 WF1 为 0.9792，高于 cls 的 0.9563 和 mean 的 0.9511。该差异说明池化位置和聚合方式会改变下游 Transformer 可利用的时序信息，均值池化并非在所有声学任务上默认最优。

4.5 样本量 × 秩

每类样本数	LoRA 秩	WA	UA	WF1
50	r=2	0.8750	0.8750	0.8750
50	r=4	0.6250	0.6250	0.5636
50	r=8	0.7500	0.7500	0.7333
50	r=16	0.6875	0.6875	0.6537
100	r=2	0.8667	0.8667	0.8661
100	r=4	0.8000	0.8000	0.7991
100	r=8	0.8333	0.8333	0.8316
100	r=16	0.8333	0.8333	0.8316
200	r=2	0.8833	0.8833	0.8830
200	r=4	0.8167	0.8167	0.8162
200	r=8	0.9500	0.9500	0.9499
200	r=16	0.8667	0.8667	0.8667
500	r=2	0.9533	0.9533	0.9533
500	r=4	0.9267	0.9267	0.9265
500	r=8	0.9533	0.9533	0.9533
500	r=16	0.9667	0.9667	0.9667




图 7 TORGO 中样本量与 LoRA 秩的二维 WF1 结果及最佳秩移动

样本量 × 秩的 16 组结果显示，每类 50、100、200 和 500 个样本时，按 WF1 选择的最佳秩依次为 r=2、r=2、r=8 和 r=16。最佳秩随数据量增加而右移，说明 LoRA 的合适秩不仅由模型决定，也受训练样本规模影响；小数据直接使用较大秩会出现明显波动。

4.6 特征层选择

任务 / 层	WA	UA	WF1
ICBHI / L1	0.8889	0.4551	0.8869
ICBHI / L4	0.8819	0.3140	0.8661
ICBHI / L7	0.8750	0.2921	0.8637
ICBHI / L10	0.8750	0.2881	0.8638
ICBHI / L12	0.8472	0.2241	0.8281
TORGO / L1	0.9793	0.9786	0.9793
TORGO / L4	0.9778	0.9745	0.9778
TORGO / L7	0.9660	0.9609	0.9660
TORGO / L10	0.9600	0.9516	0.9599
TORGO / L12	0.9608	0.9509	0.9606
SEP-28k / L1	0.7625	0.6018	0.7284
SEP-28k / L4	0.7814	0.6755	0.7707
SEP-28k / L7	0.7859	0.6662	0.7702
SEP-28k / L10	0.7814	0.6850	0.7737
SEP-28k / L12	0.7610	0.6522	0.7505

任务	最佳层	WA	UA	WF1	相对 layer 12 的 ΔWF1
ICBHI	layer 1	0.8889	0.4551	0.8869	+0.0588
TORGO	layer 1	0.9793	0.9786	0.9793	+0.0187
SEP-28k	layer 10	0.7814	0.6850	0.7737	+0.0232

Layer preference across acoustic and semantic tasks




图 8 ICBHI、TORGO 与 SEP-28k 的特征层选择对比

ICBHI 和 TORGO 的最佳层均为 layer 1，SEP-28k 的最佳层为 layer 10。该结果与论文的方向性描述一致：声学分类更依赖低层/中层表示，语义相关任务更依赖高层表示。当前比较覆盖五个层，后续仍应补齐全部 12 层并报告多随机种子的方差。

4.7 混淆矩阵

图 9 给出三个任务和三个模型的归一化混淆矩阵。ICBHI 的非对角误差集中在少数类；TORGO 的对角线接近饱和；SEP-28k 的少数类召回率较低。混淆矩阵由同一测试集预测生成，ICBHI 使用保存的 y_true/y_pred ，TORGO 与 SEP-28k 由二分类 per-class 指标精确还原。[C6]




图 9 ICBHI、TORGO、SEP-28k 的归一化混淆矩阵网格

5 讨论

本文复现支持论文的若干方向性结论。第一，领域相关的 TORGO 任务中 HuBERT-base 已接近论文水平；第二，ICBHI 的 WA 与 UA 分岔重现了类不平衡问题；第三，LoRA 的最佳秩随任务和训练规模变化，支持“秩不是固定越大越好”的结论；第四，max pooling 在 TORGO 上优于 cls 和 mean，说明池化方式是可消融的结构变量；第五，ICBHI 与 TORGO 偏好低位层，而 SEP-28k 偏好高位层，方向与论文一致。

但仍存在明显的协议差异。当前代码使用固定 seed 的分层 split，而论文使用各数据集官方或论文固定 split；ICBHI 当前测试集为 144 条，论文为 381 条；TORGO 当前为 8,990 条，论文为 8,216 条；SEP-28k 当前只有 8,800 条，论文约 27,922 条。此外，当前音频被截断到 6 秒，论文未明确采用同样处理。因此本文结果主要用于机制和趋势比较，不能视为严格数值复现。

6 复现实验代码

代码编号	文件	作用
------	----	----

C1	src/paper_transformer.py	论文版 Transformer、frozen/LoRA/full、预测保存、官方 layer 选择
C2	src/lora.py	LoRALinear、Q/K/V 注入、B 零初始化
C3	src/common.py	16 kHz 音频读取、manifest、split_by_label
C4	src/metrics.py	WA/UA/WF1 计算
C5	src/plot_rank_sweep.py	LoRA 秩曲线和 WF1 汇总图
C6	src/make_confusion_matrices.py	二分类/多分类混淆矩阵和网格图
C7	experiments/01_paper_transformer/run.sh	三模型 × 三任务 Transformer 复现命令
C8	experiments/02_lora_rank_sweep/run.sh	LoRA r=2,4,8,16 复现命令
C9	experiments/03_confusion_matrices/run.sh	混淆矩阵复现命令
C10	CODE_MANIFEST.sha256	代码文件 SHA256 校验清单
C11	REPRODUCIBILITY_CHECKLIST.md	环境、数据、运行和产物检查清单
C12	TARGET_COMPARISON.csv	论文目标、对比点、判定标准和证据映射
C13	experiments/04_layer_sweep/run.sh	逐层特征选择实验命令
C14	LAYER_SWEEP.md	层选择判定规则和当前状态
C15	GitHub Repository	公开代码仓库
C16	GitHub Release v0.3.2	代码与结果公开版本
C17	src/plot_pooling_comparison.py	池化对比表和柱状图
C18	experiments/05_pooling_comparison/run.sh	cls/mean/max 池化对照命令
C19	src/plot_data_size_rank.py	样本量 × 秩热图、曲线和最佳秩图
C20	experiments/06_data_size_rank_sweep/run.sh	样本量 × LoRA 秩二维扫描命令
C21	src/plot_layer_sweep.py	逐层 WA/UA/WF1 曲线和最佳层汇总
C22	experiments/04_layer_sweep/run_resume.sh	跳过已完成层的续跑命令

补充复现清单：REPRODUCIBILITY_CHECKLIST.md [C11]；目标对比点：TARGET_COMPARISON.csv [C12]。

复现代码公开于 GitHub：<https://github.com/armgiant30-glitch/bahbench-reproduction>。对应公开版本为 v0.3.2：<https://github.com/armgiant30-glitch/bahbench-reproduction/releases/tag/v0.3.2>。仓库包含论文版 Transformer、LoRA、池化对照、样本量×秩扫描、逐层特征实验、目标对比表、复现检查清单、结果表格、图表和混淆矩阵。

7 局限与未来工作

- 未获得 BAHBench 作者公开代码，本文代码为按论文描述自主实现。
- ICBHI、TORGO、SEP-28k 的数据版本和 split 尚不完全一致，数值只能近似比较。

- 当前只覆盖 HuBERT-base、wav2vec2-base、wav2vec2-large，未覆盖论文其余 9 个模型配置。
- 未实现真正 eGeMAPS 88 维和 ComParE-2016 6373 维。
- 未完成 OPERA-CT 的 64 Mel、64 ms 窗、32 ms 帧移前端。
- 当前为单随机种子结果，未来应报告 mean±std 和 per-class 置信区间。
- 层选择当前覆盖 1、4、7、10、12 五个层，尚未完成全部 12 层。
- LoRA r=32、64 尚未完成，类别加权消融尚未完成。
- Snore、MSTI、FluSense 因数据或标签缺失尚未完成。

8 结论

本文给出了 BAHBench 论文版 Transformer、LoRA 秩、池化方式和特征层选择的可运行复现实验。实验复现了任务难度、类别不平衡、池化差异和 LoRA 最佳秩随数据量移动的主要趋势，并观察到声学任务偏低位层、语义任务偏高位层的方向性差异。最接近论文的是 TORGO，ICBHI 仍有明显差距，SEP-28k 受数据完整性限制。本文提供了代码编号、配置、运行脚本、哈希校验和可视化结果，可作为后续严格复现与扩展实验的基线。

参考文献

- [1] Xu W, Dong Z, Peng J, Wang R, Zhang Z. BAHBench: A Unified Benchmark for Evaluating Bio-Acoustic Health With Acoustic Foundation Models. IEEE Journal of Biomedical and Health Informatics, 2025, 29(7): 4897-4909.
- [2] Baevski A, Zhou Y, Mohamed A, Auli M. wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations. NeurIPS, 2020.
- [3] Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. IEEE/ACM TASLP, 2021.
- [4] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.

附录 A 复现命令

```
bash experiments/01_paper_transformer/run.sh
bash experiments/02_lora_rank_sweep/run.sh
python src/plot_rank_sweep.py
bash experiments/03_confusion_matrices/run.sh
bash experiments/05_pooling_comparison/run.sh
bash experiments/06_data_size_rank_sweep/run.sh
```

bash experiments/04_layer_sweep/run_resume.sh

代码仓库: <https://github.com/armgiant30-glitch/bahbench-reproduction>

发布版本: <https://github.com/armgiant30-glitch/bahbench-reproduction/releases/tag/v0.3.2>

获取代码: `git clone https://github.com/armgiant30-glitch/bahbench-reproduction.git`

结果目录: results_summary/ 和 results/ 输出目录