

BAHBench 可复现性研究

论文版 Transformer 与 LoRA 秩消融实验

复现实验论文

基于 AutoDL RTX 3090 的 ICBHI、TORGO 与 SEP-28k 复现实验

代码版本: BAHBench_我的复现实验代码_20260921

摘要

本文复现 BAHBench 论文中可运行的核心实验，重点考察统一 Transformer 下游结构和 LoRA 秩消融。复现实现冻结 HuBERT-base、wav2vec2-base 和 wav2vec2-large 编码器，将音频表示投影到 768 维，并通过单层标准 Transformer 与线性分类头完成分类。实验在 ICBHI、TORGO 和 SEP-28k 三个任务上进行，统一报告 WA、UA 和 WF1。论文版 Transformer 结果显示，TORGO 与论文结果最接近，HuBERT-base 的 WF1 为 0.9606；ICBHI 仍存在明显的多数类偏置；SEP-28k 的 WA/WF1 接近论文，但 UA 偏低。LoRA 秩扫描表明最佳秩随任务变化：ICBHI 的最佳秩为 $r=2$ ，TORGO 和 SEP-28k 的最佳秩为 $r=16$ ，说明 $r=16$ 不是跨任务的普适最优值。本文同时提供代码编号、运行脚本、SHA256 校验和输出路径，以提高复现透明度。由于当前数据版本、官方 split 和样本量尚未完全对齐，本文的数值结论均按近似复现处理。

关键词：BAHBench；声学基础模型；Transformer；LoRA；可复现性；WA/UA/WF1

1 引言

BAHBench 将 Snore、ICBHI、MSTI、TORGO、SEP-28k 和 FluSense 六个健康相关音频任务放入统一下游框架，比较 12 个声学基础模型和两类手工特征。[1] 论文的核心价值在于统一数据划分、下游结构和评价指标，从而减少不同研究之间的协议差异。

本文聚焦当前已经具备可运行数据的三个任务：ICBHI、TORGO 和 SEP-28k。复现目标是验证论文的统一 Transformer 结构、比较 HuBERT 与 wav2vec2 系列模型，并分析 LoRA 秩对下游性能的影响。线性探针结果不纳入本文主实验，以免混淆论文主结构与辅助性线性分析。Code C1-C9 给出本文使用的全部复现代码。

2 方法

2.1 统一 Transformer 下游结构

基础模型权重被冻结，仅更新投影层、单层标准 Transformer 和分类头。[C1] 对输入音频 x ，基础模型输出 $h=f(x)$ ，投影层将 h 映射到 $d=768$ ，Transformer 输出再送入分类器：

$$h_tilde = \text{Transformer}(\text{Projection}(h)); p = \text{Classifier}(h_tilde[0])$$

代码实现见 `src/paper_transformer.py` 中的 `PaperTransformer` 类 [C1]。下游只使用一层 `TransformerEncoderLayer`，不以多层堆叠替代论文结构。

2.2 LoRA

LoRA 将原始线性权重 W 冻结，仅训练低秩增量 BA ，前向为 $Wx+BAx$ 。[C2] 本文把 LoRA 插入注意力 Q/K/V 投影， B 初始化为零，因此训练起点与原始模型一致。秩扫描范围为 $r=2、4、8、16$ 。

2.3 数据与评价指标

代码统一读取 16 kHz 音频 [C3]，评价指标按论文定义计算 WA、UA 和 WF1 [C4]。当前复现使用固定随机种子 0 的 70%/15%/15% 分层 split；论文使用各数据集固定 split。两者差异在结果解释中明确标注。

2.4 目标对比点与复现判定

为了让读者不只看模型分数，本文把论文目标、对比对象、判定标准和证据来源逐项列出。完整机器可读版本见 TARGET_COMPARISON.csv [C12]，复现步骤见 REPRODUCIBILITY_CHECKLIST.md [C11]。

论文目标/结论	复现状态	目标对比点	判定标准	当前证据
基础模型特征优于手工特征	未复现	模型 WF1 vs eGeMAPS/ComParE	模型 WF1 高于手工特征	待补手工特征
声学任务偏低层、语义任务偏高层	未完整复现	不同 layer 的 WF1 峰值	12 层模型：最佳层≤6 判为低中层，≥7 判为高层，峰谷差距<1pp 判为无偏好	C1、LAYER_SWEEP.md；需运行 04_layer_sweep
base 不一定优于 large	部分复现	wav2vec2-base vs wav2vec2-large	large 不必然更高	表 2、图 2
预训练领域比规模关键	未复现	OPERA-CT/WavLM vs 通用大模型	领域模型少参数反超	待补模型
LoRA 有效且秩增长后收益饱和	部分/趋势复现	r=2,4,8,16 的 WF1	最佳秩后趋稳或下降	图 4、图 5、表 3
不平衡时 WA 与 UA 分歧	已复现趋势	WA-UA 差距与少数类召回	WA 高而 UA 低	图 3、图 6
论文表 III 严格数值复现	未完成	当前结果 vs 论文同模型值	协议一致且差异约 ±2pp	图 3、表 2
六任务统一评估	未完成	6 个任务的完整指标	六任务均有完整结果	图 1

层选择的实际做法是：以 HuBERT-base 的 12 层为例，hidden_states 的 0 表示卷积前端，1-6 表示低层/中层，7-12 表示高层。保持模型、任务、split、seed 和下游 Transformer 完全一致，只改变 --layer，先跑 1,4,7,10,12 层。若最佳 WF1 出现在 1-6 层，则支持声学类任务偏好低中层；若出现在 7-12 层，则支持语义类任务偏好高层；若与最后一层差距小于 1 个百分点，则不能声称存在稳定层偏好。当前主实验默认使用最后一层，因此逐层结论尚未完成。

他人复现本论文时，需要同时满足：获得对应数据集和 manifest、安装 environment.md 中的依赖、按 run.sh 执行实验，并使用 TARGET_COMPARISON.csv 的判定标准检查输出。当前代码包可以验证代码链路，但数据版本、官方 split 和完整模型矩阵仍是数值复现的前提。

3 实验设置

项目	设置
基础模型	facebook/hubert-base-ls960; facebook/wav2vec2-base; facebook/wav2vec2-large
任务	ICBHI (8 类) ; TORGO (2 类) ; SEP-28k (2 类)
下游结构	投影到 768 维; 单层 Transformer; nhead=8; dim_feedforward=3072; dropout=0.5
训练	batch=32; epochs=50; AdamW; lr=5e-4; weight_decay=1e-2; seed=0

LoRA	Q/K/V; r=2,4,8,16; B 初始化为 0
指标	WA、UA、WF1; 并保存测试集 y_true/y_pred




图 1 六任务数据就绪度：论文数据量、标签和 split 与当前数据的覆盖差异

4 复现结果

4.1 论文版 Transformer

任务 / 模型	WA	UA	WF1	论文 WA/UA/WF1	$\Delta WF1$	标注
ICBHI / HuBERT-base	0.8472	0.2241	0.8281	0.924/0.326/0.930	-10.19	低于论文
ICBHI / wav2vec2-base	0.8750	0.3223	0.8682	0.911/0.240/0.903	-3.48	低于论文
ICBHI / wav2vec2-large	0.8333	0.1250	0.7576	0.916/0.200/0.876	-11.84	低于论文
TORG / HuBERT-base	0.9608	0.9509	0.9606	0.979/0.976/0.979	-1.84	接近论文
TORG / wav2vec2-base	0.9408	0.9399	0.9412	0.902/0.887/0.901	+4.02	高于论文但口径不同
TORG / wav2vec2-large	0.8934	0.8830	0.8940	0.858/0.841/0.857	+3.70	高于论文但口径不同
SEP-28k / HuBERT-base	0.7481	0.6283	0.7344	0.747/0.740/0.747	-1.26	接近论文
SEP-28k / wav2vec2-base	0.7262	0.6088	0.7149	0.692/0.693/0.693	+2.19	高于论文但口径不同
SEP-28k / wav2vec2-large	0.7413	0.5000	0.6312	0.732/0.710/0.724	-9.28	低于论文




图 2 论文版 Transformer 在三个任务上的 WA、UA、WF1

4.2 与论文表 III 的差异

图 3 给出当前结果与论文表 III 的 $\Delta WF1$ 。TORGO 的 HuBERT-base 与论文差距最小；ICBHI 的 wav2vec2-large 低于论文 11.84 个百分点；SEP-28k 的 wav2vec2-large 低于论文 9.28 个百分点，且 UA 为 0.5000，说明模型退化为多数类预测。




图 3 当前论文版 Transformer 相对论文表 III 的 $\Delta WF1$ 热力图

4.3 LoRA 秩扫描

任务 / 秩	WA	UA	WF1
ICBHI / r=2	0.8889	0.3952	0.8890
ICBHI / r=4	0.8333	0.3631	0.8502
ICBHI / r=8	0.8750	0.3055	0.8603
ICBHI / r=16	0.8750	0.3560	0.8698
TORGO / r=2	0.9882	0.9870	0.9882
TORGO / r=4	0.9874	0.9858	0.9874
TORGO / r=8	0.9889	0.9863	0.9889
TORGO / r=16	0.9911	0.9898	0.9911

SEP-28k / r=2	0.7844	0.6833	0.7751
SEP-28k / r=4	0.7905	0.6664	0.7730
SEP-28k / r=8	0.7920	0.6979	0.7844
SEP-28k / r=16	0.8011	0.7002	0.7911




图 4 论文版 Transformer 下的 LoRA 秩扫描曲线；圆点标出 WF1 最佳值




图 5 三个任务的最佳 LoRA WF1 与论文 HuBERT-base 对比

LoRA 结果呈现明显任务依赖：ICBHI 最佳 $r=2$ ， $WF1=0.8890$ ；TORGO 最佳 $r=16$ ， $WF1=0.9911$ ；SEP-28k 最佳 $r=16$ ， $WF1=0.7911$ 。该结果说明秩饱和阈值不是固定常数。

4.4 混淆矩阵

图 6 给出三个任务和三个模型的归一化混淆矩阵。ICBHI 的非对角误差集中在少数类；TORGO 的对角线接近饱和；SEP-28k 的少数类召回率较低。混淆矩阵由同一测试集预测生成，ICBHI 使用保存的 y_true/y_pred ，TORGO 与 SEP-28k 由二分类 per-class 指标精确还原。[C6]

BAHBench Paper Transformer Confusion Matrices




图 6 ICBHI、TORGO、SEP-28k 的归一化混淆矩阵网格

5 讨论

本文复现支持论文的若干方向性结论。第一，领域相关的 TORGO 任务中 HuBERT-base 已接近论文水平；第二，ICBHI 的 WA 与 UA 分岔重现了类不平衡问题；第三，LoRA 的最佳秩随任务变化，支持“秩不是固定越大越好”的结论；第四，SEP-28k 的结果表明 WF1 提高并不必然伴随少数类召回提升。

但仍存在明显的协议差异。当前代码使用固定 seed 的分层 split，而论文使用各数据集官方或论文固定 split；ICBHI 当前测试集为 144 条，论文为 381 条；TORGO 当前为 8,990 条，论文为 8,216 条；SEP-28k 当前只有 8,800 条，论文约 27,922 条。此外，当前音频被截断到 6 秒，论文未明确采用同样处理。因此本文结果主要用于机制和趋势比较，不能视为严格数值复现。

6 复现实验代码

代码编号	文件	作用
C1	src/paper_transformer.py	论文版 Transformer、frozen/LoRA/full、预测保存、官方 layer 选择

C2	src/lora.py	LoRALinear、Q/K/V 注入、B 零初始化
C3	src/common.py	16 kHz 音频读取、manifest、split_by_label
C4	src/metrics.py	WA/UA/WF1 计算
C5	src/plot_rank_sweep.py	LoRA 秩曲线和 WF1 汇总图
C6	src/make_confusion_matrices.py	二分类/多分类混淆矩阵和网格图
C7	experiments/01_paper_transformer/run.sh	三模型 × 三任务 Transformer 复现命令
C8	experiments/02_lora_rank_sweep/run.sh	LoRA r=2,4,8,16 复现命令
C9	experiments/03_confusion_matrices/run.sh	混淆矩阵复现命令
C10	CODE_MANIFEST.sha256	代码文件 SHA256 校验清单
C11	REPRODUCIBILITY_CHECKLIST.md	环境、数据、运行和产物检查清单
C12	TARGET_COMPARISON.csv	论文目标、对比点、判定标准和证据映射
C13	experiments/04_layer_sweep/run.sh	逐层特征选择实验命令
C14	LAYER_SWEEP.md	层选择判定规则和当前状态

补充复现清单：REPRODUCIBILITY_CHECKLIST.md [C11]；目标对比点：TARGET_COMPARISON.csv [C12]。

完整代码包和结果摘要位于桌面 BAHBench_我的复现实验代码 目录，压缩包为 BAHBench_我的复现实验代码_20260921.zip。线性探针代码和结果未纳入本文主实验，已移入旧版归档。

7 局限与未来工作

- 未获得 BAHBench 作者公开代码，本文代码为按论文描述自主实现。
- ICBHI、TORGO、SEP-28k 的数据版本和 split 尚不完全一致，数值只能近似比较。
- 当前只覆盖 HuBERT-base、wav2vec2-base、wav2vec2-large，未覆盖论文其余 9 个模型配置。
- 未实现真正 eGeMAPS 88 维和 ComParE-2016 6373 维。
- 未完成 OPERA-CT 的 64 Mel、64 ms 窗、32 ms 帧移前端。
- 当前为单随机种子结果，未来应报告 mean±std 和 per-class 置信区间。
- Snore、MSTI、FluSense 因数据或标签缺失尚未完成。

8 结论

本文给出了 BAHBench 论文版 Transformer 和 LoRA 秩扫描的可运行复现实验。代码层面已通过 frozen 与 LoRA 冒烟测试，实验结果复现了任务难度、类别不平衡和 LoRA 秩饱和的主要趋势。最接近论文的是 TORGO，ICBHI 仍有明显差距，SEP-28k 受数据完整性限制。本文提供了代码编号、配置、运行脚本、哈希校验和可视化结果，可作为后续严格复现与扩展实验的基线。

参考文献

- [1] Xu W, Dong Z, Peng J, Wang R, Zhang Z. BAHBench: A Unified Benchmark for Evaluating Bio-Acoustic Health With Acoustic Foundation Models. IEEE Journal of Biomedical and Health Informatics, 2025, 29(7): 4897-4909.
- [2] Baevski A, Zhou Y, Mohamed A, Auli M. wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations. NeurIPS, 2020.
- [3] Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units. IEEE/ACM TASLP, 2021.
- [4] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.

附录 A 复现命令

`bash experiments/01_paper_transformer/run.sh`

`bash experiments/02_lora_rank_sweep/run.sh`

`python src/plot_rank_sweep.py`

`bash experiments/03_confusion_matrices/run.sh`

代码包 ZIP: C:/Users/violet/Desktop/BAHBench_我的复现实验代码_20260921.zip

结果目录: results_summary/ 和 results/ 输出目录